马晓晨

xiaochen.ma.cs@gmail.com · xiaochen.ma@connect.ust.hk
ma.xiaochen.world · SunnyHaze · Google Scholar · LinkedIn

研究方向

大语言模型数据准备与高性能分布式系统，重点研究数据算子管理、任务编排，以及基于 Ray 和 Apache Spark 的大规模数据处理。

教育经历

香港科技大学 中国香港
计算机科学与工程博士 *2026 年 2 月 – 预计 2028 年*
导师：袁彬航教授、张文涛教授。

四川大学 中国成都
计算机科学与技术工学学士 *2019 年 9 月 – 2023 年 6 月*
本科毕业论文获评四川大学优秀本科毕业论文。

科研与实习经历

腾讯混元基础模型部 中国北京
研究实习生，青云计划 *2026 年 6 月 – 至今*

- 基于 Ray 和 Apache Spark 开发大模型数据准备系统，完善数据算子管理，方便算子的使用、分发和实验复现。
- 开发面向数据去重、聚类及大规模文档与视频处理的分布式流水线。

北京大学 中国北京
研究助理，导师：张文涛教授 *2025 年 1 月 – 2026 年 1 月*

- 负责 DataFlow 项目研发，协调 10 余名同学参与系统设计、开发、代码审查、集成与发布。
- 设计数据处理流水线和算子接口，开发存储与服务接口，支持基于 Ray 的分布式执行。

四川大学 中国成都
全职研究助理，导师：周吉喆教授 *2023 年 7 月 – 2024 年 6 月*

- 共同设计并开发 IMDLBenCo，为图像篡改检测与定位提供统一的训练、评测框架和实验基准。
- 研究图像篡改检测方法与高效视觉模型，开展可复现的对比实验，相关成果发表于 NeurIPS、AAAI 和 ICCV。

代表性系统与开源项目

DataFlow [代码] [论文] 项目负责人

- 面向大模型数据准备的开源框架，提供近 200 个可复用算子和 6 条通用流水线，可组合数据生成、清洗、评估等处理步骤；论文获 **SIGMOD'27** 接收。
- 参与核心架构设计与实现；具体工作包括流水线编译与执行、算子注册、存储与服务接口、命令行工具及分布式执行。

RayOrch [代码] [论文] 一作、项目发起人

- 设计面向文档和视频处理的数据流编程模型与分布式执行引擎，记录拆分后各条数据的来源和完成状态，并按原有顺序汇总结果。
- 负责基于 Ray 的执行机制，处理任务数量随输入变化时的任务调度、结果汇总与错误处理，并集成至 DataFlow。

Flash-MinerU [代码] 项目发起人及核心开发者

- 基于 Ray 加速 MinerU 的 PDF 转 Markdown 处理，让不同阶段交错执行，支持多 GPU、多节点批量解析文档。

代表性论文

*共同贡献。完整论文列表见 *Google Scholar*。

1. **Xiaochen Ma**, Zimo Meng, Junzhu Liang, et al. *RayOrch: Programming and Executing Lineage-Controlled Multi-Grain Dataflows for Foundation-Model Data Preparation.* **arXiv'26**。[论文] [代码]
2. Hao Liang*, **Xiaochen Ma***, et al. *DataFlow: An LLM-Driven Framework for Unified Data Preparation and Workflow Automation in the Era of Data-Centric AI.* 已被 **SIGMOD'27** 接收。[论文] [代码]
3. **Xiaochen Ma***, Xuekang Zhu*, Lei Su*, Bo Du*, Zhuohang Jiang*, Bingkui Tong*, Zeyu Lei*, Xinyu Yang*, Chi-Man Pun, Jiancheng Lv, and Jizhe Zhou. *IMDL-BenCo: A Comprehensive Benchmark and Codebase for Image Manipulation Detection and Localization.* **NeurIPS'24 Spotlight**。[论文] [代码]
4. Xuekang Zhu*, **Xiaochen Ma***, Lei Su, Zhuohang Jiang, Bo Du, Xiwen Wang, Zeyu Lei, Wentao Feng, Chi-Man Pun, and Jizhe Zhou. *Mesoscopic Insights: Orchestrating Multi-scale and Hybrid Architecture for Image Manipulation Localization.* **AAAI'25**。[论文] [代码]
5. Bo Du*, Xuekang Zhu*, **Xiaochen Ma***, Chenfan Qu*, Kaiwen Feng*, Zhe Yang, Chi-Man Pun, Jian Liu, and Ji-Zhe Zhou. *ForensicHub: A Unified Benchmark and Codebase for All-Domain Fake Image Detection and Localization.* **NeurIPS'25**。[论文] [代码]
6. Lu Ma, Hao Liang, Meiyi Qiang, Lexiang Tang, **Xiaochen Ma**, et al. *Learning What Reinforcement Learning Can't: Interleaved Online Fine-Tuning for Hardest Questions.* **ICLR'26**。[论文]
7. Yuran Wang, Bohan Zeng, Chengzhuo Tong, Wenxuan Liu, Yang Shi, **Xiaochen Ma**, Hao Liang, Yuanxing Zhang, and Wentao Zhang. *Scone: Bridging Composition and Distinction in Subject-Driven Image Generation via Unified Understanding-Generation Modeling.* **CVPR'26 Highlight**。[论文]
8. Bo Du, **Xiaochen Ma**, Xuekang Zhu, et al. *Can We Build a Monolithic Model for Fake Image Detection? SICA: Semantic-Induced Constrained Adaptation for Unified-Yet-Discriminative Artifact Feature Space Reconstruction.* **ICML'26**。[论文] [代码]
9. Jizhe Zhou, **Xiaochen Ma**, Xia Du, Ahmed Y. Alhammadi, and Wentao Feng. *Pre-training-free Image Manipulation Localization through Non-Mutually Exclusive Contrastive Learning.* **ICCV'23**。[论文]

学术服务

会议审稿：AAAI'27；NeurIPS'26、BMVC'26、ECCV'26、CVPR'26、ICLR'26、AISTATS'26；AAAI'25、NeurIPS'25、ICCV'25、ICML'25、CVPR'25、ICLR'25、AISTATS'25；NeurIPS'24、ACM MM'24。

荣誉与奖励

优秀本科毕业论文，四川大学 *2023 年 6 月*
全国二等奖，中国软件杯大学生软件设计大赛 *2022 年 10 月*

技术能力与语言

- **编程与系统**：Python、C/C++、Ray、Apache Spark、PyTorch、Docker、Linux、Git、Bash、LaTeX。
- **语言**：中文（母语）；英语（IELTS 7.0，GRE 324）。